


跨國關鍵字分析系統


從海量數據到商業決策

數據工程專題

- ☐ 台灣
- ☐ 西班牙
- ☐ 美國
- ☐ 英國
- ☐ 香港
- ☐ 澳洲



real madrid vs girona



1 day ago · Real Madrid suffer La Liga title blow as they are held to a home draw by...

專案：解構跨國情報的數據並整合

痛點與挑戰

耗時低效：手動蒐集跨國情報極度耗時，難以應對快速變化的市場。

資料碎片化：數據散落在不同平台，缺乏統一格式與維度關聯。

決策滯後：缺乏即時監控機制，導致企業錯失高爆發力商機。

解決方案與預期效益

自動化管線：建立 End-to-End 流程，實現從爬取到決策的自動化。

AI 語意賦能：利用 LLM 進行正規化，解決同義詞造成的數據失真。

精準鎖定：提升報表產出效率，即時捕捉市場爆發點。

架構藍圖：雲端驅動的端到端數據管線



自動化爬取



AI 語意整理



倉儲分析



視覺化決策



基礎設施

Azure SQL Database

Docker 部署

GitHub CI/CD 協作



任務排程

Apache Airflow DAG

自動重試機制

錯誤警報通知



開發工具

Python (Selenium)

Gemini API (LLM)

Power BI (DAX)

爬蟲開發:反爬機制


伺服器資源最佳化 → 摒棄傳統 GUI
算力開銷, 降低伺服器記憶體佔用,
實現輕量化部署。

瀏覽器特徵偽裝 →
AutomationControlled 與隨機
User-Agent 模擬真人。

```
def init_driver(self):
    try:
        print(f"[INFO] Initializing Chromium WebDriver (Headless Mode)")

        driver_path = "/usr/bin/chromedriver"
        options = webdriver.ChromeOptions()
        options.add_argument("--headless=new")
        options.add_argument("--window-size=1920,1080")
        options.add_argument("--no-sandbox")
        options.add_argument("--disable-dev-shm-usage")
        options.add_argument("--disable-gpu")
        options.add_argument("--remote-allow-origins=*")
        options.add_argument("--disable-blink-features=AutomationControlled")
        options.add_argument("user-agent=Mozilla/5.0 (X11; Linux x86_64) AppleWebKit")
        self.profile_path = f"/tmp/Chrome_Temp_{int(time.time())}"
        options.add_argument(f"--user-data-dir={self.profile_path}")
        service = Service(driver_path)
        self.driver = webdriver.Chrome(service=service, options=options)
        self.driver.set_page_load_timeout(PAGE_LOAD_TIMEOUT)

        print(f"[INFO] Linux Chromium WebDriver initialized successfully")
```



- 1.節省伺服器記憶體
- 2.偽裝成一般使用者

數據採集: Python 爬蟲與資源管理實踐

爬蟲開發核心技術

動態等待機制: 使用 WebDriverWait 確保元素加載完成, 提升採集成功率。

模擬真實行為: 隨機 User-Agent 與操作延遲, 有效繞過反爬蟲機制。

多執行緒加速: ThreadPoolExecutor 實作並行採集, 顯著提升數據吞吐量。

爬蟲瀏覽器的PID清除

系統穩定性與資源優化

殭屍程序清理: 利用 psutil 強制清除無效瀏覽器行程, 防止記憶體洩漏。

```
# psutil 清理邏輯
for proc in psutil.process_iter():
    target_processes = [ 'chrome', 'chromedriver',
                        'chromium', 'msedge', 'edge']
    if clean_name in target_processes:
        proc.kill()
```

異常重試策略: 結合 Airflow 自動重試, 確保管線在網路波動時仍能穩定運行。

效能優化: 記憶體內比對與批次防禦性寫入

1. 【降低 DB I/O】將現有資料批次拉回記憶體 (In-memory) 建立 Hash Map

```
query = f"SELECT Keyword, KeywordID FROM KeywordsMaster WHERE Keyword IN ({placeholders})"
```

```
cursor.execute(query, chunk)
```

```
for row in cursor.fetchall():
```

```
    existing_keywords[row[0].lower()] = int(row[1])
```

在記憶體中完成新增與更新

2. 【提升寫入效能】使用 executemany 進行批次新增與更新

```
if insert_params:
```

```
    insert_query = "INSERT INTO KeywordsMaster (...) VALUES (?, ?, ?, ?, GETDATE())"
```

```
    cursor.executemany(insert_query, insert_params)
```

避免一次一次呼叫資料庫

```
if update_params:
```

```
    update_query = "UPDATE KeywordsMaster SET Category = ?, SearchIntent = ? WHERE KeywordID = ?"
```

```
    cursor.executemany(update_query, update_params)
```


```
self.conn.commit()
```

環境隔離解決方案: Docker + WSL 2 跨平台架構

環境設定

1. 系統不相容: Apache Airflow 原生僅支援 POSIX 系統 (Linux/macOS), 直接在 Windows 運行會面臨路徑解析、權限管理與底層庫相容性的重重困難。

2 底層虛擬化解決方案: 利用 Windows Subsystem for Linux (WSL 2) 核心, 在 Windows 底層打造高效能的 Linux 原生運行環境, 完美消除 OS 層級的差異。




Airflow 自動化配置流程：Docker-Compose 實踐

1. 開發與正式環境 100% 一致：透過容器化消除環境變數痛點。

2. 跨平台無痛部署：透過 docker-compose.yaml 將 Airflow 多個微服務整合。

3. 依賴套件集中管理：統一管理 requirements.txt 與系統套件，確保 Python 爬蟲與 AI 腳本的依賴版本絕對鎖定與隔離。



系統觀測性:雙向日誌追蹤

[進度] 106/121 處理完成。

[成功] '蔬果': 6 番石榴、香蕉、鳳梨、桃子、李子、花果菜類:西瓜、甜瓜、苦...

[進度] 107/121 處理完成。

[成功] '輝達': 瞭解更多關於 NVIDIA 公司歷史、領導團隊、徵才職缺、全...

[進度] 108/121 處理完成。

[成功] '霍宏聲': 5 days ago · 沙田馬場周一(6日)舉行賽馬期間發...

[進度] 109/121 處理完成。

[成功] '鍾嘉欣': Latest News 2026-03-01 「Rememb...

[進度] 110/121 處理完成。

[成功] '寵物': Wepet 寵物資訊平台提供公立收容所之認養資料及寵物、浪浪...

[進度] 111/121 處理完成。

[成功] '穩定幣': Oct 21, 2025 · 穩定幣因價格穩定、結合區塊鏈優...

[進度] 112/121 處理完成。

[成功] '补贴': 补贴, 津贴 是一种普遍实施于特定个人、家庭或企业的经济援助...

確認資料有寫入資料庫中

133 %

找不到任何問題

行: 1, 字元: 26 | TAB | CRLF | UTF

結果 訊息

	LogID	KeywordID	LogDate	CrawlTime	SummaryText	Status	ErrorMessage	CreatedAt
76...	8523	7378	2026-04-11	2026-04-11 09:06:15.800	16 hours ago · 我有望加入RCEP、CPTPP? 鄭麗文: 習近平釋善意「什麼事都可以商量」 眾所矚目的「鄭習會」...	Success	NULL	2026-04-11 09
76...	8524	7367	2026-04-11	2026-04-11 09:06:15.800	3 days ago · 愛惜券幣 貨幣的故事 什麼是貨幣 貨幣的演進 券幣萬花筒 券幣達人 新型態數位貨幣 我國券幣的歷...	Success	NULL	2026-04-11 09
76...	8525	7386	2026-04-11	2026-04-11 09:06:15.800	13 hours ago · 《痞子英雄》中飾演何小玫的喻虹淵(如圖), 和周渝民結婚後淡出演藝圈10來年, 38歲的地宣...	Success	NULL	2026-04-11 09
76...	8526	7385	2026-04-11	2026-04-11 09:06:15.800	富喬 (1815.TWO), Yahoo股市 Yahoo奇摩股市提供您即時報價、個股走勢、成交資訊、當日籌碼、價量變化、...	Success	NULL	2026-04-11 09
76...	8527	7352	2026-04-11	2026-04-11 09:06:15.800	17 hours ago · 新皇崗口岸將於2026年內啟用, 並將採用「一地兩檢」及「合作查驗、一次放行」模式, 設134條...	Success	NULL	2026-04-11 09
76...	8528	7375	2026-04-11	2026-04-11 09:06:15.800	Aug 6, 2025 · 銅箔 本文深入剖析銅箔在電子產業中扮演的關鍵角色, 全面探討其製程技術、結構特性與應用情...	Success	NULL	2026-04-11 09
76...	8529	7370	2026-04-11	2026-04-11 09:06:15.800	22 hours ago · 檢方調查, 李能謙自2014年間起, 即透過公司與人脈蒐集軍方相關資訊, 後於2024年赴中國廣州...	Success	NULL	2026-04-11 09
76...	8530	7368	2026-04-11	2026-04-11 09:06:15.803	6 番石榴、香蕉、鳳梨、桃子、李子、花果菜類:西瓜、甜瓜、苦瓜、絲瓜、扁蒲、茄子、長豇(菜)豆、毛...	Success	NULL	2026-04-11 09
76...	8531	7380	2026-04-11	2026-04-11 09:06:15.803	瞭解更多關於 NVIDIA 公司歷史、領導團隊、徵才職缺、全球據點、投資人關係等訊息。...	Success	NULL	2026-04-11 09
76...	8532	7354	2026-04-11	2026-04-11 09:06:15.803	5 days ago · 沙田馬場周一(6日)舉行賽馬期間發生馬匹受傷事故。 今日第4場、途程1,400米的賽事中, 2號馬...	Success	NULL	2026-04-11 09
76...	8533	7358	2026-04-11	2026-04-11 09:06:15.803	Latest News 2026-03-01 「Remember記得 · 鍾嘉欣演唱會」佛山站encore場將於2026年4月18日於佛山嶺南明珠體...	Success	NULL	2026-04-11 09
76...	8534	7371	2026-04-11	2026-04-11 09:06:15.803	Wepet 寵物資訊平台提供公立收容所之認養資料及寵物、浪浪與毛小孩們的送養、領養、認養、走失協尋、最...	Success	NULL	2026-04-11 09

AI 賦能: Gemini 整合與語意正規化策略

語意處理核心

Gemini API 整合: 利用大語言模型處理跨國關鍵字的語意碎片化問題。

自動分類與意圖判定: 精準識別搜尋意圖(如: 購買、資訊、導航)與產業類別。

金鑰輪替機制: 實作 API Key Rotation 策略, 確保在高併發請求下突破 Rate Limit。

效能優化: 採用 ThreadPoolExecutor 進行批次處理, 提升 300% 處理效率。

> Prompt Engineering

結構化輸出約束: 嚴格要求模型輸出 JSON 格式, 確保數據管線穩定讀取。

```
prompt = f"""請將以下關鍵字分類到適當的 Category 和 SearchIntent。【核心指令：絕對禁止翻譯中文】：1. 絕對禁止翻譯「中文」關鍵字。中文關鍵字請保持原樣填入 'english_translation' 欄位。2. 只有非英文的外語需要翻譯成英文並填入 'english_translation'。3. 如果是英文, 'english_translation' 直接填入原本的關鍵字。4. 如果你不確定 SearchIntent, 請預設填入 "Informational"。絕對不可以留空或回傳 null。
```


Few-shot Prompting: 提供高品質範例, 引導模型在複雜語境下保持分類一致性。

AI 演進：自動化語意規則擴充系統

使用多執行緒提高效能，速度提升300%

自動化學習閉環 (核心邏輯)

Automated Learning Loop (Core Logic)



```
with concurrent.futures.ThreadPoolExecutor(max_workers=min(3, len(batches))) as executor:  
    future_to_batch = {executor.submit(call_ai_for_deep_learning, batch): i for i, batch in enumerate(batches)}  
    for future in concurrent.futures.as_completed(future_to_batch):  
        try:  
            res = future.result()  
            if res:  
                ai_results.update(res)  
        except Exception as exc:  
            logger.error(f"批次學習發生錯誤: {exc}")
```

```
if updated_count > 0:  
    with open(RULES_FILE, 'w', encoding='utf-8') as f:  
        json.dump(rules, f, ensure_ascii=False, indent=4)  
    logger.info(f"規則檔已擴充 {updated_count} 個新詞彙。")
```

維度

自動化前

自動化後

分類覆蓋率

65% (固定規則)

98%+ (動態學習)

維護成本

需手動分類

AI自動補完

突破 API 限制: 高可用金鑰輪替與無縫錯誤恢復機制

面臨挑戰: 批次處理海量關鍵字時, 單一 API 金鑰極易觸發 429 (Too Many Requests) 錯誤導致管線中斷。

金鑰匙輪替 (Key Pool): 建立多組 API 金鑰陣列, 透過全域索引 (Index) 進行狀態追蹤。

無縫錯誤恢復: 偵測到連線異常或扣打耗盡時, 利用取餘數 (%) 演算法自動切換下一把金鑰並重試, 確保 ETL 流程的穩定。

```
for _ in range(len(GEMINI_API_KEYS) * 2):
    key = GEMINI_API_KEYS[CURRENT_API_KEY_INDEX]
    try:
        url = f"https://generativelanguage.googleapis.com/v1beta/models/gemini-2"
        res = requests.post(url, json=payload, headers=headers, timeout=30)
        if res.status_code == 200:
            result = safe_process_response(res)
            if result: return result
    except: pass
    CURRENT_API_KEY_INDEX = (CURRENT_API_KEY_INDEX + 1) % len(GEMINI_API_KEYS)


return {kw: classify_keyword_by_rules(kw) for kw in keywords_list}
```

規則分類: Rule-based 降級容錯機制

防禦機制: 當 API 金鑰池全數耗盡, 或遇雲端伺服器全面中斷等極端狀況時, 系統將自動觸發防禦機制。

本地端備援路由: 利用預建的 Python 字典與特徵字串進行決定性分類, 確保程式持續運行。

```
def classify_keyword_by_rules(keyword):  
    """規則式分類 (AI 失敗時的 Fallback)"""  
  
    kw_lower = keyword.lower()  
    intent = "Informational"  
    # 交易型  
    if any(word in kw_lower for word in ['buy', 'price', 'cheap', 'discount', 'order', '買', '價格', '便  
        | intent = "Transactional"  
    # 商業調查型  
    elif any(word in kw_lower for word in ['best', 'review', 'vs', 'compare', 'top', '推薦', '評價', '比  
        | intent = "Commercial"  
    # 導航型  
    elif any(word in kw_lower for word in ['login', 'official', 'www', '官網', '登入', '客服', '下載']):  
        | intent = "Navigational"  
  
    category = "Other"  
    # 商業與金融 (含金量最高)  
    if any(word in kw_lower for word in ['stock', 'market', 'bank', 'finance', '股票', '股市', '銀行', '  
        | category = "Business"  
    # 科技與3C  
    elif any(word in kw_lower for word in ['iphone', 'apple', 'app', 'software', 'tech', '手機', '蘋果']  
        | category = "Technology"  
    # 體育賽事
```




數據建模: 星狀模型設計

星狀模型 (Star Schema)

事實表 (Fact Tables): 存放關鍵字搜尋量、爆發指數等行為紀錄。

維度表 (Dimension Tables): 存放實體特徵, 如國家、語系、AI 分類標籤。




倉儲實體化：星狀模型架構

邏輯架構具象化：將抽象的星狀模型精準落地至 SQL Server，建立具備強型別與關聯約束的實體資料表。

高內聚低耦合：嚴格區分維度表 與事實表，最佳化商業智慧 (BI) 工具的查詢效能。

系統與品質日誌：獨立建置 CrawlerExecutionLog 與 DataQualityLog，完整追蹤爬蟲狀態與數據生命週期，確保管線具備 100% 的可稽核性。




The screenshot shows a list of tables in a SQL Server database named 'THE TABLE'. The tables are organized into folders: '外部資料表' (External Tables) and '圖形資料表' (Graphical Tables). The '圖形資料表' folder contains several tables, some of which are highlighted with red boxes. The highlighted tables are 'dbo.CrawlerExecutionLog', 'dbo.DailyTrendSnapshots', and 'dbo.DimDate'. Other tables listed include 'dbo.DataQualityLog', 'dbo.DataQualityRules', 'dbo.KeywordCoOccurrence', 'dbo.KeywordRegionStats', 'dbo.KeywordsLog', 'dbo.KeywordsMaster', 'dbo.QualityAlerts', 'dbo.RegionsMaster', and 'dbo.RelatedQueriesLog'. At the bottom, there is a folder labeled '已卸除的總帳資料表' (Discontinued General Ledger Tables).

Table Name
外部資料表
圖形資料表
dbo.CrawlerExecutionLog
dbo.DailyTrendSnapshots
dbo.DataQualityLog
dbo.DataQualityRules
dbo.DimDate
dbo.KeywordCoOccurrence
dbo.KeywordRegionStats
dbo.KeywordsLog
dbo.KeywordsMaster
dbo.QualityAlerts
dbo.RegionsMaster
dbo.RelatedQueriesLog
已卸除的總帳資料表


效能與維運：預存程序封裝

SQL下推計算：存放關鍵字搜尋量、爆發指數等行為紀錄
將關聯度計算、排名異動等運算邏輯封裝為 usp_ 預存程序，交由資料庫底層執行。

邏輯封裝：確保前端儀表板與後端 ETL 共用同一套運算標準，降低系統維護成本。



商業洞察: Power BI 互動式戰情室與價值矩陣



👁 視覺化設計與降噪

神經網路關聯圖：直觀呈現關鍵字間的連動生態系，識別核心節點。

DAX 核心運算：自定義爆發成長率公式，量化市場潛力。




掃描進行互動

AI 語意圖譜：從 SQL 底層演算法到神經網路視覺化

```
SET
CoOccurrenceScore = CASE
-- 兩個關鍵字都在 Top 10：最強關聯
WHEN k1.AvgRank <= 10 AND k2.AvgRank <= 10 THEN 95.0
-- 兩個關鍵字都在 Top 25：強關聯
WHEN k1.AvgRank <= 25 AND k2.AvgRank <= 25 THEN 80.0
-- 兩個關鍵字都在 Top 50：中等關聯
WHEN k1.AvgRank <= 50 AND k2.AvgRank <= 50 THEN 60.0
-- 其他：弱關聯
ELSE 40.0
END
FROM dbo.KeywordCoOccurrence kc
```

階層化降噪：透過 SQL 強制將關聯度收斂為 95、80、60 等級距，作為網路圖的連線粗細依據。



核心DAX邏輯:透過多維度權重計算爆發成長率

正向放大器:結合[常態流量]、[AI 意圖權重]與[跨國共鳴度], 找出高價值標的。

反向阻力:以[熱搜名次]為分母, 名次越小, 爆發力分數越高。

防禦性除法:寫入 ISBLANK 與 SafeRank 邏輯, 阻絕 Divide by Zero 導致的儀表板崩潰。

```
1 爆發指數 =  
2  VAR TotalVol = [常態搜尋量]  
3  VAR AvgRank = [Google 熱搜榜平均名次]  
4  VAR Resonance = [跨國共鳴度]  
5  VAR BaseIntent = MAX('KeywordsMaster'[意圖])  
6  VAR BaseCat = MAX('KeywordsMaster'[產業])  
7  VAR SafeRank = IF(ISBLANK(AvgRank) || AvgRank = 0, 1, AvgRank)  
8  
9  RETURN  
10 DIVIDE(  
11     (TotalVol * BaseIntent * BaseCat * Resonance),  
12     SafeRank  
13 )
```

技術挑戰、成長軌跡與未來展望

✖ 技術挑戰與克服

並行死鎖 (Deadlock) : 優化資料庫 Transaction 與 Locking 機制, 解決高併發寫入衝突。

髒資料正規化 : 從 Rule-based 進化為 AI-based 的 Entity Resolution, 大幅提升數據準確度。

資源洩漏 : 實作自動清理機制解決 WebDriver 殭屍程序, 確保系統長期運行穩定。

✎ 個人成長與思維

全棧數據視野 : 掌握從採集、清洗、建模到洞察的完整 Data Pipeline 生命週期。

架構師思維 : 從單一腳本開發轉向考慮系統擴展性、容錯性與自動化的架構設計。

NEXT STEPS: 未來技術藍圖

引入 Apache Kafka & Spark Streaming 實現即時數據處理。

使用 Merge into 的方式來處理大量的資料。



掃描觀看原始碼

感謝您的聆聽與指教